

第六章



参数估计

Estimation of Parameters

参数

- (1) 分布中所含未知参数;
- (2) 未知参数的函数;
- (3) 分布的各种特征数。

一般常用 θ 表示参数, 参数 θ 所有可能取值组成的集合称为参数空间, 常用 Θ 表示。

问题:

设 θ 表示未知参数, X_1, \dots, X_n 为来自总体的样本。

- (1) 如何给出 θ 的估计, 比如构造估计量 $\bar{\theta} = \bar{\theta}(X_1, \dots, X_n)$;
- (2) 如何评价估计量的好坏(评价标准)。

第一节：点估计 (Point Estimation)

参数估计问题就是根据样本对未知参数作出估计。

参数估计的形式有两种：

- **点估计**：给出参数的估计量
- **区间估计**：给出参数的估计范围及其包含参数的可信度

第一节：点估计

问题的提法：

设总体 X 的分布函数为 $F(x, \theta)$, 形式已知, 含未知参数 θ , 有样本 X_1, \dots, X_n , 及观测值 x_1, \dots, x_n .

构造估计量 $\bar{\theta} = \bar{\theta}(X_1, \dots, X_n)$ 作为 θ 的估计量;
用观测值 $\bar{\theta}(x_1, \dots, x_n)$ 作为 θ 的估计值。

■ 点估计的两种方法：

- 矩估计法 (Method of Moments)
- 最大似然估计 (Maximum Likelihood Estimate)

第一节：点估计

- A **point estimate** of a parameter:
 - **a single number** that can be regarded as a sensible value for the parameter.
 - obtained by selecting a **suitable statistic** and computing its value from the given sample data.
- The selected statistic is called the **point estimator** of the parameter.

一、矩估计法 (Method of Moments)

替换原理：用样本的 AAA 替换总体的 AAA.

- (1) 用样本矩 替换 总体矩 (矩：原点距或中心距)；
- (2) 用样本矩的函数 替换 总体矩的函数；
- (3) 用经验分布函数 替换 总体的分布函数；
- (4) 用样本的分位数 替换 总体的分位数；
- (5) 用事件发生的频率 替换 事件发生的概率；
-

“替换” 得到方程，解之。

思想

- From weak LLN, for iid variables, a sample moment converges to the population moment:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k = E(X^k).$$

- Equate sample moments to population moments:
Sample moments = Population moments

$$\begin{cases} A_1 = \mu_1(\theta), \\ \dots \\ A_k = \mu_k(\theta). \end{cases}$$

- The **point estimate** is found by **solving** the above equation(s) for the parameters.

步骤：设 X 为离散型RV, $P(X = x) = p(x; \theta_1, \dots, \theta_k)$;

或为连续型RV, $f(x) = f(x; \theta_1, \dots, \theta_k)$; 共有 k 个参数。

Step 1: 计算总体直到 k 阶矩: μ_1, \dots, μ_k (用未知参数表示);

$$\mu_j = E(X^j) = b_j(\theta_1, \dots, \theta_k);$$

Step 2: 解出未知参数, 用总体矩表示
$$\begin{cases} \theta_1 = g_1(\mu_1, \dots, \mu_k), \\ \dots \\ \theta_k = g_k(\mu_1, \dots, \mu_k). \end{cases}$$

Step 3: 用样本矩替换总体矩:
$$\begin{cases} \bar{\theta}_1 = g_1(A_1, \dots, A_k), \\ \dots \\ \bar{\theta}_k = g_k(A_1, \dots, A_k). \end{cases}$$

则 $\bar{\theta}_1, \dots, \bar{\theta}_k$ 为未知参数 $\theta_1, \dots, \theta_k$ 的矩估计量。

若有 $\theta_1, \dots, \theta_k$ 的函数 $\eta = h(\theta_1, \dots, \theta_k)$, 则 $\bar{\eta} = h(\bar{\theta}_1, \dots, \bar{\theta}_k)$ 为 η 的矩估计量。

理论依据

设 X_1, \dots, X_n 是来自该总体 X 的样本,

样本 k 阶原点矩: $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$.

定理: 设总体 X 的 k 阶矩存在: $E(X^k) = \mu_k$,

则: (1) $A_k \xrightarrow{P} \mu_k$. (用辛钦大数定律)

(2) $g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k)$ (g 为连续函数)。

矩法估计的实质是用**经验分布函数**去替换**总体分布函数**, 其理论基础是格里纹科定理 —— **经验分布函数是总体分布函数的一致良好近似**。

矩估计量可能不唯一, 尽量采用低阶矩。

例：设总体 $X \sim U[0, \theta]$. 求 θ 的矩估计量。

解：Step 1: 计算总体一阶矩： μ_1 (用未知参数表示);

$$\mu_1 = E(X) = \frac{\theta}{2};$$

Step 2: 反解出未知参数，用总体矩表示

$$\theta = 2\mu_1.$$

Step 3: 用样本矩[↑]替换总体矩:

$$\bar{\theta} = 2A_1 = 2\bar{X}.$$

则 θ 的矩估计量为 $\bar{\theta} = 2A_1 = 2\bar{X}$.

例：设总体 $X \sim U[-\theta, \theta]$. 求 θ 的矩估计量。

解：Step 1: 计算总体一阶矩： μ_1 (用未知参数表示);

$$\mu_1 = E(X) = 0; \quad (\text{与未知参数无关!})$$

计算总体二阶矩： μ_2 (用未知参数表示);

$$\mu_2 = E(X^2) = \theta^2 / 3;$$

Step 2: 反解出未知参数，用总体矩表示

$$\theta = \sqrt{3\mu_2}.$$

Step 3: 用样本矩替换总体矩:

$$\bar{\theta} = \sqrt{3A_2}$$

则 θ 的矩估计量为 $\bar{\theta} = \sqrt{3A_2}$.

例：设总体 X 为指数分布 $f(x, \lambda) = \lambda \cdot e^{-\lambda x}, x > 0$. 求 λ 的矩估计量。

解：Step 1: 计算总体一阶矩： μ_1 (用未知参数表示)

$$\mu_1 = E(X) = \frac{1}{\lambda};$$

原点矩

Step 2: 反解出未知参数，用总体矩表示

$$\lambda = \frac{1}{\mu_1}.$$

Step 3: 用样本矩替换总体矩

$$\bar{\lambda} = \frac{1}{A_1} = \frac{1}{\bar{X}}$$

则 λ 的矩估计量为 $\bar{\lambda} = \frac{1}{\bar{X}}$.

另解：Step 1: 计算总体二阶(中心)矩：

$$D(X) = 1/\lambda^2;$$

Step 2: 反解出未知参数，用总体矩表示

$$\lambda = 1/\sqrt{D(X)}.$$

Step 3: 用样本矩替换总体矩： $\bar{\lambda} = 1/S$

则 λ 的矩估计量为 $\bar{\lambda} = 1/S$.

例：设总体 $X \sim U[a, b]$. 求 a, b 的矩估计量。

解：Step 1: 计算总体矩(原点或中心矩, 用未知参数表示)

$$E(X) = \frac{a+b}{2}, \quad D(X) = \frac{(b-a)^2}{12}.$$

$$\Rightarrow \begin{cases} a+b = 2E(X) \\ b-a = \sqrt{12D(X)} \end{cases}$$

Step 2: 反解出未知参数，用总体矩表示

$$\Rightarrow \begin{cases} a = E(X) - \sqrt{3D(X)} \\ b = E(X) + \sqrt{3D(X)} \end{cases}$$

原点矩

中心矩

Step 3: 用样本矩替换总体矩: $\begin{cases} \bar{a} = A_1 - \sqrt{3} S, \\ \bar{b} = A_1 + \sqrt{3} S. \end{cases}$

例：

设总体 X 的均值 μ 及方差 σ^2 存在,但未知,求 μ, σ^2 的矩估计量。

解：Step 1: 计算总体一阶、二阶原点矩:(用未知参数表示);

$$\mu_1 = E(X) = \mu,$$

$$\mu_2 = E(X^2) = \sigma^2 + \mu^2.$$

Step 2: 反解出未知参数, 用总体矩表示

$$\Rightarrow \begin{cases} \mu = \mu_1, \\ \sigma^2 = \mu_2 - \mu_1^2. \end{cases}$$

原点矩 原点矩

Step 3: 用样本矩替换总体矩:
$$\begin{cases} \bar{\mu} = A_1 = \bar{X}, \\ \bar{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \end{cases}$$

分别是:
样本均值
样本方差

注：结果与总体分布无关。

例：

设总体 X 服从自由度为 m 的 χ^2 分布, m 未知, 求 m 的矩估计量。

解：

Step 1: 计算总体的一阶矩(用未知参数表示)：

$$\mu_1 = E(X) = m.$$

Step 2: 反解出未知参数, 用总体矩表示

$$\Rightarrow m = \mu_1.$$

Step 3: 用样本矩替换总体矩：

$$\bar{\mu} = A_1 = \bar{X}.$$

例：甲乙两人独立地校对某书样稿。校完后，甲发现a个错字，乙发现b个错字，共同发现的错字有c个。试用矩估计法估计：

(1) 该书样稿总错字数； (2) 未被发现的错字数。

解：(1) 设该书样稿总错字数为 d 。设甲、乙识别错字的概率分别为 P_1 和 P_2 。由独立性，同一错字能被甲、乙同时识别的概率为

$$P = P_1 \cdot P_2,$$

由频率替换概率的思想

$$\Rightarrow \begin{cases} P_1 \approx \bar{P}_1 = a/d, \\ P_2 \approx \bar{P}_2 = b/d, \\ P \approx \bar{P} = c/d. \end{cases}$$

$$\text{近似有: } \bar{P} = \bar{P}_1 \cdot \bar{P}_2 \Rightarrow \frac{c}{d} = \frac{a}{d} \cdot \frac{b}{d} \Rightarrow \bar{d} = \frac{ab}{c}.$$

(2) 未被发现的错字数的估计是总错字数的估计减去

$$\text{甲、乙发现的错字数, 即为 } \bar{d} - (a + b - c) = \frac{ab}{c} - a - b + c.$$

二、最大似然估计

Maximum Likelihood Estimate (1821 Gauss, 1922 Fisher)

最大似然思想：

有两个射手甲和乙，命中率分别为 0.9 和 0.1. 现在他们中的一个向目标射击了一发，结果命中了。**是谁射击的？**

分析：如果是甲，则 $P(\text{命中}) = 0.90$;

如果是乙，则 $P(\text{命中}) = 0.10$.

所以，“最像” 是甲命中的。

或者：

$$P(\text{甲} | \text{命中}) = \frac{P(\text{命中} | \text{甲}) \cdot P(\text{甲})}{P(\text{命中} | \text{甲}) \cdot P(\text{甲}) + P(\text{命中} | \text{乙}) \cdot P(\text{乙})} = 0.9.$$

最大似然思想

一般，事件 A 发生的概率与某参数 $\theta \in \Theta$ 有关，
参数 θ 取值不同，则概率 $P(A)$ 也不同。
事件 A 发生的概率应记为 $P(A|\theta)$ 。

若 A 发生了，则认为此时的 θ 值应是在所有可能参数 Θ
中使事件 A 发生的概率 $P(A|\theta)$ **达到最大** (最像) 的那一个。

最大似然思想

- This method has an intuitive appeal to it, since it asks **the question:**

For what parameter value is the observed data most likely to have arisen?

- **The maximum likelihood principle**

Given a dataset, choose the parameter(s) in such a way that the data are **most likely**.

例：

设有来自Poisson总体 $P(\lambda)$ 的样本观测值：

$X_1=4, X_2=7, X_3=2$. 哪个 λ 最可能？

$$\begin{aligned} P(X_1 = 4, X_2 = 7, X_3 = 2) &= \frac{\lambda^4}{4!} e^{-\lambda} \cdot \frac{\lambda^7}{7!} e^{-\lambda} \cdot \frac{\lambda^2}{2!} e^{-\lambda} \\ &= \frac{\lambda^{13}}{4!7!2!} e^{-3\lambda}. \end{aligned}$$

选取 λ , 使上述概率最大。

$$\log\left(\frac{\lambda^{13}}{4!7!2!} e^{-3\lambda}\right) = 13\log(\lambda) - 3\lambda - \log(4!7!2!).$$

求导, 令之为0, 得 $\lambda = 13 / 3$.

二阶导 <0 , 确为最大值点。

1. 总体为离散型

设 $P(X = x) = p(x; \theta), \theta \in \Theta$ (参数空间, 即参数可能取值全体)。

X_1, \dots, X_n 为样本, x_1, \dots, x_n 为观测值。

则样本 (X_1, \dots, X_n) 取到观测值 (x_1, \dots, x_n) 的概率为:

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p(x_i; \theta).$$

定义: $L(\theta) := \prod_{i=1}^n p(x_i; \theta)$, 称 $L(\theta)$ 为样本的似然函数。

不同的参数 θ , $L(\theta)$ 不同。

问题: 参数 θ 取什么值时, 概率 $P(X_1 = x_1, \dots, X_n = x_n)$ 最大?

即哪个 θ 最可能导致 $\{X_1 = x_1, \dots, X_n = x_n\}$ 的发生?

最大似然思想: 选择 $\theta \in \Theta$, 使 $L(\theta)$ 达到最大。

最大似然估计

Maximum Likelihood Estimate, MLE

定义：如果 $\bar{\theta} = \bar{\theta}(x_1, \dots, x_n)$ 满足

$$L(\bar{\theta}) := \max_{\theta \in \Theta} L(\theta),$$

则称 $\bar{\theta}$ 为 θ 的最大似然估计(MLE),

$\bar{\theta}(x_1, \dots, x_n)$ 为MLE估计值,

$\bar{\theta}(X_1, \dots, X_n)$ 为MLE估计量。

2. 总体为连续型

设总体 X 的密度： $f(x; \theta), \theta \in \Theta$ (参数空间)。

X_1, \dots, X_n 为样本， x_1, \dots, x_n 为观测值。

则 (X_1, \dots, X_n) 的联合密度为： $\prod_{i=1}^n f(x_i; \theta)$ 。

随机向量 (X_1, \dots, X_n) 落在观测点 (x_1, \dots, x_n) 的邻域(不是一点)的概率：

$$\prod_{i=1}^n f(x_i; \theta) \cdot \prod_{i=1}^n dx_i \quad (\text{概率微元, 后者与}\theta\text{无关})$$

这个概率与 θ 有关。

最大似然思想：选择 $\theta \in \Theta$ ，使上述概率达到最大。

2. 总体为连续型

定义： $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ 为样本的似然函数。

如果 $\bar{\theta} = \bar{\theta}(x_1, \dots, x_n)$ 满足

$$L(\bar{\theta}) := \max_{\theta \in \Theta} L(\theta),$$

则称 $\bar{\theta}$ 为 θ 的最大似然估计(MLE),

$\bar{\theta}(x_1, \dots, x_n)$ 为MLE估计值,

$\bar{\theta}(X_1, \dots, X_n)$ 为MLE估计量。

注记:

似然函数 vs 联合分布密度函数

不同的视角:

似然函数形式上等于样本的联合分布密度函数,

但似然函数是未知参数 θ 的函数(其中的 x_i 为确定的观测值)

在联合分布中, x_i 为变量, θ 为已知参数(固定)。

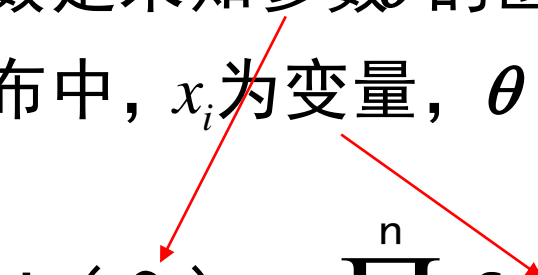


Diagram illustrating the relationship between the variables in the text and the equation:

- A red arrow points from the x_i in the text "其中的 x_i 为确定的观测值" to the x_i in the equation.
- A red arrow points from the θ in the text " θ 为已知参数(固定)" to the θ in the equation.

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

注记：

- 可把参数 θ 和样本 X_1, \dots, X_n 分别看成“原因”和“结果”。
- 定了 θ 的值，就完全确定了样本分布，也就定下了得到种种结果的可能性的的大小。
- 反过来，当有了结果（样本）时，我们问：当参数 θ 取各种不同的值（原因）时，导出这个结果的可能性有多大？这导出“似然”函数的概念。“似然”——“看起来像”。
- 在已得样本的情况下，不能唯一决定 θ 。
取哪个值去估计 θ 呢？——取那个“看起来最像”的值，
即，使得“似然”函数达到最大的那个 θ 值。

3. 求MLE的方法

Step 1: 写出似然函数: $L(\theta) = \begin{cases} \prod_{i=1}^n p(x_i; \theta), & \text{总体为离散型,} \\ \prod_{i=1}^n f(x_i; \theta), & \text{总体为连续型.} \end{cases}$

Step 2: 求似然函数 $L(\theta)$ 的最大值点。

方法1: 如 $p(x; \theta)$, $f(x; \theta)$ 关于 θ 可微,

令: $\frac{dL(\theta)}{d\theta} = 0$, 解出 θ , 再讨论它是否为最大值点。

方法2: 对数似然函数 $\ln L(\theta) = \sum \ln f(x_i; \theta)$.

$L(\theta)$ 与 $\ln L(\theta)$ 在同一 θ 处取得最大值(因 $\ln x$ 单调).

令: $\frac{d \ln L(\theta)}{d\theta} = 0$, 解出 θ , 再讨论它是否为最大值点。

方法3: 其它方法(观察法), 求 $\bar{\theta}$, 满足 $L(\bar{\theta}) := \max_{\theta \in \Theta} L(\theta)$.

3. 求MLE的方法

推广到多个参数的情形:

Step 1: 写出似然函数: $L(\theta) = \begin{cases} \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_k), & \text{总体为离散型,} \\ \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_k), & \text{总体为连续型.} \end{cases}$

Step 2: 求似然函数 $L(\theta_1, \dots, \theta_k)$ 或对数似然函数 $\ln L(\theta_1, \dots, \theta_k)$ 的最大值点。

$$\text{令: } \begin{cases} \frac{\partial L(\theta_1, \dots, \theta_k)}{\partial \theta_1} = 0, \\ \vdots \\ \frac{\partial L(\theta_1, \dots, \theta_k)}{\partial \theta_k} = 0, \end{cases} \quad \text{或} \quad \begin{cases} \frac{\partial \ln L(\theta_1, \dots, \theta_k)}{\partial \theta_1} = 0, \\ \vdots \\ \frac{\partial \ln L(\theta_1, \dots, \theta_k)}{\partial \theta_k} = 0, \end{cases}$$

解出 $(\theta_1, \dots, \theta_k)$, 再讨论它是否为最大值点。

需要判断对应的 Hessian 矩阵是否为“非正定”

4. MLE举例

例：产品质量 X 分为合格($X=0$)与不合格($X=1$), 不合格率为 p

(未知)。抽得样本： $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$. 求 p 的 MLE.

解：总体的分布： $X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$. 即 $P(X = x) = p^x (1-p)^{1-x}, x = 0, 1$.

似然函数 $L(p) = P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$

$$= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum x_i} (1-p)^{n-\sum x_i}.$$

对数似然函数： $\ln L(p) = (\sum x_i) \ln p + (n - \sum x_i) \ln(1-p)$.

$$\text{令 } \frac{d \ln L(p)}{dp} = \left(\sum x_i \right) \frac{1}{p} - \left(n - \sum x_i \right) \frac{1}{1-p} = 0,$$

解得 $\bar{p} = \frac{1}{n} \sum x_i$, 又 $\ln L(p)$ 关于 p 的二阶导数 < 0 .

\Rightarrow MLE估计值为 $\bar{p} = \frac{1}{n} \sum x_i$, MLE估计量为 $\bar{p} = \frac{1}{n} \sum X_i$. (与矩估计相同)

例:

设总体: $X \sim \begin{pmatrix} a & b & c \\ \theta^2 & 2\theta(1-\theta) & (1-\theta)^2 \end{pmatrix}$, θ 为参数。

现做了 n 次试验, 观测到 a, b, c 分别出现 n_1, n_2, n_3 次。求 θ 的 MLE.

解: 似然函数

$$\begin{aligned} L(\theta) &= P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n) \\ &= C [\theta^2]^{n_1} \cdot [2\theta(1-\theta)]^{n_2} \cdot (1-\theta)^{2n_3} = C 2^{n_2} \theta^{2n_1+n_2} \cdot (1-\theta)^{n_2+2n_3}. \end{aligned}$$

对数似然函数:

此处 C 为多项系数, 与参数 θ 无关

$$\ln L(\theta) = (2n_1 + n_2) \ln \theta + (n_2 + 2n_3) \ln(1-\theta) + \ln C + n_2 \ln 2.$$

$$\text{令 } \frac{d \ln L(\theta)}{d\theta} = (2n_1 + n_2) \frac{1}{\theta} - (n_2 + 2n_3) \frac{1}{1-\theta} = 0,$$

解得 $\bar{\theta} = \frac{2n_1 + n_2}{2n}$, 又 $\ln L(\theta)$ 关于 θ 的二阶导数 < 0 .

\Rightarrow MLE 估计值为 $\bar{\theta} = \frac{2n_1 + n_2}{2n}$.

例

设总体 $X \sim P(\lambda)$, λ 为参数。设有观测值 x_1, \dots, x_n ,
求 λ 的 MLE.

解：总体的分布列 $f(k; \lambda) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$

似然函数 $L(\lambda) = \frac{\lambda^{x_1}}{x_1!} e^{-\lambda} \dots \frac{\lambda^{x_n}}{x_n!} e^{-\lambda} = \frac{\lambda^{x_1 + \dots + x_n}}{x_1! \dots x_n!} e^{-n\lambda}.$

对数似然函数：

$$\ln L(\lambda) = (x_1 + \dots + x_n) \ln(\lambda) - n\lambda - \ln(x_1! \dots x_n!).$$

令 $\frac{\ln L(\lambda)}{d\lambda} = (x_1 + \dots + x_n) \cdot \frac{1}{\lambda} - n$, 解得 $\bar{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$

再计算二阶导数，易知为负，上述解为 MLE.

例

设总体 $X \sim N(\mu, \sigma^2)$, (μ, σ^2) 为参数. 设有观测值 x_1, \dots, x_n , 求 μ, σ^2 的 MLE.

解: 总体的密度 $f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi} \sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$.

似然函数

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi} \sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right).$$

对数似然函数: $\ln L(\mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2} \ln(\sigma^2) - \frac{n}{2} \ln(2\pi).$

$$\text{令} \begin{cases} \frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0, \\ \frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2} = 0, \end{cases} \quad \text{解得} \begin{cases} \bar{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \\ \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{cases}$$

再计算 Hessian 矩阵, 可判定为非正定. 上述解为 MLE (与矩估计相同).

$$\theta = \sigma^2$$

注：并非在所有场合均可求导

设总体 $X \sim U[a, b]$, a, b 未知, x_1, \dots, x_n 为观测值, 求 a, b 的 MLE.

解：记 $x_{(1)} = \min\{x_1, \dots, x_n\}$, $x_{(n)} = \max\{x_1, \dots, x_n\}$.


总体 X 的密度 $f(x) = \frac{1}{b-a} \cdot \mathbf{I}_{\{a \leq x \leq b\}}$.

$$\text{似然函数: } L(a, b) = \prod_{i=1}^n \frac{1}{b-a} \cdot \mathbf{I}_{\{a \leq x_i \leq b\}} = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)}, \\ 0, & \text{其它。} \end{cases}$$

对满足 $a \leq x_{(1)}, b \geq x_{(n)}$ 的所有 a, b , 均有

作为 a, b 的函数

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$



在 $a = x_{(1)}, b = x_{(n)}$ 时, 等号成立, 即 $L(a, b)$ 达最大。

故 a, b 的 MLE 为 $\bar{a} = x_{(1)} = \min\{x_1, \dots, x_n\}, \bar{b} = x_{(n)} = \max\{x_1, \dots, x_n\}$.

注：并非在所有场合均可求导

$$\text{似然函数: } L(a, b) = \prod_{i=1}^n \frac{1}{b-a} \cdot \mathbf{I}_{\{a \leq x_i \leq b\}} = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)}, \\ 0, & \text{其它。} \end{cases}$$

对满足 $a \leq x_{(1)}, b \geq x_{(n)}$ 的所有 a, b ,


$$\ln L(a, b) = -n \ln(b-a).$$

$$\frac{\partial \ln L(a, b)}{\partial a} = n/(b-a) > 0, \quad \frac{\partial \ln L(a, b)}{\partial b} = -n/(b-a) < 0.$$

表明 $\ln L(a, b)$ 对 a 单调上升, a 最大时最好, $\bar{a} = x_{(1)} = \min\{x_1, \dots, x_n\}$.

$\ln L(a, b)$ 对 b 单调下降, b 最小时最好, $\bar{b} = x_{(n)} = \max\{x_1, \dots, x_n\}$.

故 a, b 的MLE为 $\bar{a} = x_{(1)} = \min\{x_1, \dots, x_n\}, \bar{b} = x_{(n)} = \max\{x_1, \dots, x_n\}$.



5. MLE的不变性

设 $\bar{\theta}$ 是 θ 的MLE, 即 $L(\bar{\theta}) = \max_{\theta \in \Theta} L(\theta)$.

又设 $\eta = g(\theta)$ (一一对应的函数), 则 $\bar{\eta} := g(\bar{\theta})$ 是 η 的MLE.

因关于 η 的似然函数 $L^*(\eta)$ 可由关于 θ 的似然函数 $L(\theta)$ 通过代人 $\theta = g^{-1}(\eta)$ 得到:

$$L^*(\eta) = L(g^{-1}(\eta)) = L(\theta),$$

$$\Rightarrow L^*(\bar{\eta}) = L(g^{-1}(\bar{\eta})) = L(\bar{\theta}),$$

因 $\bar{\theta}$ 使 $L(\theta)$ 达最大, 所以 $\bar{\eta} := g(\bar{\theta})$ 使 $L^*(\eta)$ 达最大。

不变性使一些复杂结构的参数的极大似然估计容易得到

例

设总体 $X \sim N(\mu, \sigma^2)$, (μ, σ^2) 为参数。

设有观测值 x_1, \dots, x_n , 已求出 μ, σ^2 的MLE是:

$$\begin{cases} \bar{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \\ \bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = (s^*)^2. \end{cases}$$

\Rightarrow 标准差 σ 的MLE是: $\bar{\sigma} = s^*$. (标准差 = $\sqrt{\text{方差}}$)

概率 $\eta := P(X < 2) = \Phi\left(\frac{2 - \mu}{\sigma}\right)$ 的MLE是 $\bar{\eta} = \Phi\left(\frac{2 - \bar{x}}{s^*}\right)$.

第二节、点估计的评价标准

- ❑ Two different methods (method of moments, MLE) of finding estimators for population parameters have been introduced.
- ❑ We have seen that it is possible to have several estimators for the same parameter.
- ❑ Should we use the method of moments estimator, the MLE, or an estimator obtained through some other methods?

一、相合性

- 点估计是一个统计量，是RV，在样本量一定的条件下，不可能要求它完全等同于参数的真值。
- 随着样本量的不断增大，经验分布函数逼近真实分布函数，因此可以要求估计量随着样本量的不断增大而逼近参数真值，这就是相合性。
- 相合性是对估计的一个最基本要求。如果一个估计量，在样本量不断增大时，它都不能近似被估参数到任意指定的精度，那么这个估计是值得怀疑的。

一、相合性

大意：估计量随着样本容量的增大而“逼近”真参数。


定义：设 $\bar{\theta}_n = \bar{\theta}_n(X_1, \dots, X_n)$ 为参数 θ 的估计量，

若 $\bar{\theta}_n \xrightarrow{P} \theta$,

即 $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|\bar{\theta}_n - \theta| \geq \varepsilon) = 0$,

或 $\lim_{n \rightarrow \infty} P(|\bar{\theta}_n - \theta| < \varepsilon) = 1$.

则称 $\bar{\theta}_n$ 为 θ 的相合估计。



证明相合性可用：各种大数定律或依概率收敛的性质。

例(续)

设 X_1, \dots, X_n 是来自该总体 X 的样本, 样本 k 阶原点矩为

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k. \text{ 设总体 } X \text{ 的 } k \text{ 阶矩存在: } E(X^k) = \mu_k,$$

则: (1) $A_k \xrightarrow{P} \mu_k$. (用辛钦大数定律)

(2) $g(A_1, \dots, A_k) \xrightarrow{P} g(\mu_1, \dots, \mu_k)$ (g 为连续函数)。

表明: A_k 为 μ_k 的相合估计,

$g(A_1, \dots, A_k)$ 为 $g(\mu_1, \dots, \mu_k)$ 的相合估计。

例:

特别，样本方差

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \xrightarrow{P} \mu_2 - \mu_1^2 = \sigma^2.$$

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \left(\frac{n}{n-1} \right) \cdot \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 \right) \xrightarrow{P} \sigma^2.$$

↑
(依概率) 趋于1

即两种样本方差均为总体方差的相合估计。

相合性的判定

定理：设 $\bar{\theta}_n = \bar{\theta}_n(X_1, \dots, X_n)$ 为参数 θ 的一个相合估计量，

$\eta = g(\theta)$ 是 θ 的连续函数，

则 $\bar{\eta}_n := g(\bar{\theta}_n)$ 为 η 的相合估计。

证：因 $\bar{\theta}_n \xrightarrow{P} \theta$ ，又 $\eta = g(\theta)$ 是 θ 的连续函数，

由依概率收敛的性质

$$g(\bar{\theta}_n) \xrightarrow{P} g(\theta).$$

即 $\bar{\eta}_n = g(\bar{\theta}_n)$ 为 η 的相合估计。

注：此处 θ 可为向量。

矩估计一般都是样本矩的连续函数，
由该定理，一般具有相合性

相合性的判定定理:

设 $\bar{\theta}_n = \bar{\theta}_n(X_1, \dots, X_n)$ 为参数 θ 的一个估计量,

若 $\lim_{n \rightarrow +\infty} E(\bar{\theta}_n) = \theta$, $\lim_{n \rightarrow +\infty} D(\bar{\theta}_n) = 0$, 则 $\bar{\theta}_n$ 为 θ 的相合估计。

证: 注意到 $\bar{\theta}_n - \theta = [\bar{\theta}_n - E(\bar{\theta}_n)] + [E(\bar{\theta}_n) - \theta]$.

由Chebyshev不等式有 $P(|\bar{\theta}_n - E(\bar{\theta}_n)| > \varepsilon) \leq \frac{D(\bar{\theta}_n)}{\varepsilon^2}$.

因 $\lim_{n \rightarrow +\infty} D(\bar{\theta}_n) = 0$, 所以 $\bar{\theta}_n \xrightarrow{P} E(\bar{\theta}_n)$, 即 $\bar{\theta}_n - E(\bar{\theta}_n) \xrightarrow{P} 0$.

又 $\lim_{n \rightarrow +\infty} E(\bar{\theta}_n) = \theta$, 所以 $E(\bar{\theta}_n) \xrightarrow{P} \theta$, 即 $E(\bar{\theta}_n) - \theta \xrightarrow{P} 0$.

(因 n 充分大时, 必 $|E(\bar{\theta}_n) - \theta| < \varepsilon \Rightarrow P(|E(\bar{\theta}_n) - \theta| > \varepsilon) = 0$.)

$$\bar{\theta}_n - \theta = [\bar{\theta}_n - E(\bar{\theta}_n)] + [E(\bar{\theta}_n) - \theta] \xrightarrow{P} 0$$

则 $\bar{\theta}_n$ 为 θ 的相合估计。

二、无偏性

定义：


设 $\bar{\theta}_n = \bar{\theta}_n(X_1, \dots, X_n)$ 为参数 θ 的估计量，

若 $E(\bar{\theta}_n) = \theta \quad (\forall \theta \in \Theta)$

则称 $\bar{\theta}_n$ 为 θ 的无偏估计。否则称为有偏估计。

注： $E(\bar{\theta}_n) - \theta$ 称为“系统误差”
无偏性就是无系统误差。

MLEs or moment estimators
are not, in general, unbiased.



例：设总体 X 的均值 μ 及方差 σ^2 存在，但未知，

$$\mu, \sigma^2 \text{ 的矩估计量: } \begin{cases} \bar{\mu} = A_1 = \bar{X}, \\ \bar{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = (S^*)^2. \end{cases}$$

显然， $E(\bar{\mu}) = E(\bar{X}) = \mu \Rightarrow \bar{\mu}$ 为 μ 的无偏估计量；

$$\text{又 } E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \sigma^2 \text{ (已证)}$$

即： S^2 是 σ^2 的无偏估计量。

$$\begin{aligned} \text{但, } E[(S^*)^2] &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= \left(\frac{n-1}{n}\right) E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2. \end{aligned}$$

$\Rightarrow (S^*)^2$ 不是 σ^2 的无偏估计量(是渐近无偏估计量).

注记:

无偏估计不具有不变性。

设 $\bar{\theta}$ 是 θ 的无偏估计, 又设 $\eta = g(\theta)$,
则 $\bar{\eta} := g(\bar{\theta})$ 一般不是 η 的无偏估计。

如: 设 $\bar{\theta}$ 是 θ 的无偏估计, 且 $D(\bar{\theta}) > 0$,

则 $(\bar{\theta})^2$ 不是 θ^2 的无偏估计。

因为 $E(\bar{\theta}) = \theta$,

所以 $E[(\bar{\theta})^2] = D(\bar{\theta}) + [E(\bar{\theta})]^2 = D(\bar{\theta}) + \theta^2 > \theta^2$.

三、有效性


定义：

设 $\bar{\theta}_1, \bar{\theta}_2$ 为参数 θ 的两个无偏估计，

若 $\forall \theta \in \Theta$, 有 $D(\bar{\theta}_1) \leq D(\bar{\theta}_2)$,

且至少有一个 $\theta \in \Theta$, 使上述不等号严格成立，

则称 $\bar{\theta}_1$ 比 $\bar{\theta}_2$ 更有效。



例:

设总体 X 的均值 μ 及方差均 σ^2 存在，但未知。

作估计量： $\bar{\mu}_1 = X_1$, $\bar{\mu}_2 = \bar{X}$.

则 $E(\bar{\mu}_1) = E(X_1) = \mu$,

$$E(\bar{\mu}_2) = E(\bar{X}) = \mu.$$

即 $\bar{\mu}_1, \bar{\mu}_2$ 均为 μ 的无偏估计量。

但 $D(\bar{\mu}_1) = D(X_1) = \sigma^2$,

$$D(\bar{\mu}_2) = D(\bar{X}) = \sigma^2 / n,$$

这表明用全部数据的平均估计总体均值要比只使用部分数据更有效。

所以，当 $n > 1$ 时， $\bar{\mu}_2$ 比 $\bar{\mu}_1$ 更有效。

例： 设总体 $X \sim U[0, \theta]$, θ 未知, X_1, \dots, X_n 为样本。

(1) 求 θ 的MLE $\bar{\theta}_{\text{MLE}}$.

(2) 修正 $\bar{\theta}_{\text{MLE}}$, 使之成为无偏估计, 记为 $\bar{\theta}_{\text{修}}$.

(3) 比较 $\bar{\theta}_{\text{修}}$ 与 θ 的矩估计(记为 $\bar{\theta}_{\text{矩}}$) 的有效性。


解:(1) 记 $x_{(n)} = \max\{x_1, \dots, x_n\}$. 总体 X 的密度 $f(x) = \frac{1}{\theta} \cdot \mathbf{I}_{\{0 \leq x \leq \theta\}}$.

$$\text{似然函数: } L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \cdot \mathbf{I}_{\{0 \leq x_i \leq \theta\}} = \frac{1}{\theta^n} \cdot \mathbf{I}_{\{\theta \geq x_{(n)}\}}.$$

$$\text{对满足 } \theta \geq x_{(n)} \text{ 的所有 } \theta, \text{ 均有 } L(\theta) = \frac{1}{\theta^n} \leq \frac{1}{(x_{(n)})^n},$$

在 $\theta = x_{(n)}$ 时, 等号成立.

故 θ 的MLE为 $\bar{\theta}_{\text{MLE}} = X_{(n)} = \max\{X_1, \dots, X_n\}$.



例(续)

(2) $\bar{\theta}_{\text{MLE}}$ =: Z 的分布函数为 $F_{\text{Max}}(z) = (z/\theta)^n, 0 \leq z \leq \theta$,
其密度函数 $f_{\text{Max}}(z) = n z^{n-1} / \theta^n, 0 \leq z \leq \theta$.

$$\Rightarrow E(\bar{\theta}_{\text{MLE}}) = \int_0^\theta z f_{\text{Max}}(z) dz = \frac{n}{n+1} \theta \quad (\text{即 } \bar{\theta}_{\text{MLE}} \text{ 有偏}).$$

$$\text{令 } \bar{\theta}_{\text{修}} = \frac{n+1}{n} \bar{\theta}_{\text{MLE}}$$

$$\Rightarrow E(\bar{\theta}_{\text{修}}) = \frac{n+1}{n} E(\bar{\theta}_{\text{MLE}}) = \theta, \text{ 即 } \bar{\theta}_{\text{修}} \text{ 无偏}.$$

例(续)

解:(3). θ 的矩估计为 $\bar{\theta}_{\text{矩}} = 2\bar{X}$.

设总体 $X \sim U[0, \theta]$. 求 θ 的矩估计量。

解: Step 1: 计算总体一阶矩: μ_1 (用未知参数表示);

$$\mu_1 = E(X) = \frac{\theta}{2};$$

Step 2: 反解出未知参数, 用总体矩表示 $\theta = 2\mu_1$.

Step 3: 用样本矩替换总体矩: $\bar{\theta} = 2A_1 = 2\bar{X}$.

则 θ 的矩估计量为 $\bar{\theta} = 2A_1 = 2\bar{X}$.

$$\Rightarrow E(\bar{\theta}_{\text{矩}}) = E(2\bar{X}) = 2 \cdot \frac{\theta}{2} = \theta. \quad (\text{无偏})$$

$$D(\bar{\theta}_{\text{矩}}) = 4D(\bar{X}) = 4 \cdot D(X) / n = 4 \cdot \theta^2 / (12n) = \theta^2 / (3n). (*)$$

因 $\bar{\theta}_{\text{MLE}}$ 的密度函数 $f_{\text{Max}}(z) = n z^{n-1} / \theta^n, 0 \leq z \leq \theta$.

$$\Rightarrow D(\bar{\theta}_{\text{MLE}}) = \frac{n}{(n+1)^2(n+2)} \theta^2$$

$$\text{因 } \bar{\theta}_{\text{修}} = \frac{n+1}{n} \bar{\theta}_{\text{MLE}}$$

$$\Rightarrow D(\bar{\theta}_{\text{修}}) = \left(\frac{n+1}{n} \right)^2 D(\bar{\theta}_{\text{MLE}}) = \frac{1}{n(n+2)} \theta^2 (**).$$

比较(*)与(**), 当 $n > 1$ 时, $3n < n(n+2) \Rightarrow \bar{\theta}_{\text{修}}$ 比 $\bar{\theta}_{\text{矩}}$ 更有效。

注记：上例中矩估计量和MLE的相合性

(1) 矩估计 $\bar{\theta}_{\text{矩}}$ 是 θ 的相合估计.

证：由大数律 $\bar{X} \xrightarrow{P} \frac{\theta}{2}$ (独立同分布, 方差有限),

所以 $\bar{\theta}_{\text{矩}} = 2\bar{X} \xrightarrow{P} \theta$.

或者由Chebyshev不等式：

$$0 < \mathbf{P}(|\bar{\theta}_{\text{矩}} - \theta| \geq \varepsilon) \leq \frac{\mathbf{D}(\bar{\theta}_{\text{矩}})}{\varepsilon^2} = \frac{\theta^2}{3n\varepsilon^2} \rightarrow 0.$$

注记：上例中矩估计量和MLE的相合性

(2) 最大似然估计 $\bar{\theta}_{\text{MLE}}$ 是 θ 的相合估计.


$$\text{证: } E(\bar{\theta}_{\text{MLE}}) = \frac{n}{n+1} \theta \rightarrow \theta,$$

$$\text{且 } D(\bar{\theta}_{\text{MLE}}) = \frac{n\theta^2}{(n+1)^2(n+2)} \rightarrow 0 \quad (n \rightarrow +\infty),$$

由以前的定理, $\bar{\theta}_{\text{MLE}}$ 是 θ 的相合估计。(相合性判定定理)

$$\begin{aligned} \text{或者: } 0 < P(|\bar{\theta}_{\text{MLE}} - \theta| \geq \varepsilon) &= \int_{|z-\theta| \geq \varepsilon} n \frac{z^{n-1}}{\theta^n} dz \\ &= \int_0^{\theta-\varepsilon} n \frac{z^{n-1}}{\theta^n} dz = \frac{(\theta-\varepsilon)^n}{\theta^n} \rightarrow 0. \quad \underline{(z \leq \theta)} \end{aligned}$$

Theta 的epsilon 邻域之外积分




四、均方误差

Two point estimates may have:

- different expectations and
- different variances.

How to compare them?



Bias low
Var low
(a)



Bias high
Var low
(b)



Bias low
Var high
(c)



Bias high
Var high
(d)

定义：均方误差

设 $\bar{\theta}$ 为参数 θ 的估计量，定义

$\text{MSE}(\bar{\theta}) := E(\bar{\theta} - \theta)^2$ 为均方误差。

点估计值与参数真值的距离平方的期望

均方误差的分解：

$$\begin{aligned}\text{MSE}(\bar{\theta}) &= E(\bar{\theta} - \theta)^2 = E\{[\bar{\theta} - E(\bar{\theta})] + [E(\bar{\theta}) - \theta]\}^2 \\ &= D(\bar{\theta}) + [E(\bar{\theta}) - \theta]^2 + 2E\{[\bar{\theta} - E(\bar{\theta})] \cdot [E(\bar{\theta}) - \theta]\} \\ &= D(\bar{\theta}) + [E(\bar{\theta}) - \theta]^2 = \text{方差} + \text{系统偏差的平方}.\end{aligned}$$

注记：

系统偏差

对无偏估计，第二项为0，MSE准则就是方差(有效性)准则。

对有偏估计，应使MSE越小越好。

均方误差是评价点估计的最一般的标准。

无偏估计 不一定 比有偏估计更优。

例: 设总体 $X \sim U[0, \theta]$.

$\bar{\theta}_{\text{MLE}} = X_{(n)} = \max\{X_1, \dots, X_n\}$ 是 θ 的MLE, 是有偏的。

令 $\bar{\theta}_{\text{修}} = \frac{n+1}{n} X_{(n)} \Rightarrow E(\bar{\theta}_{\text{修}}) = \frac{n+1}{n} E(X_{(n)}) = \theta$, 即 $\bar{\theta}_{\text{修}}$ 无偏。

$$\text{MSE}(\bar{\theta}_{\text{修}}) = D(\bar{\theta}_{\text{修}}) = \frac{1}{n(n+2)} \theta^2. \quad (\text{上例已计算})$$

另作形如 $\bar{\theta}_a = a X_{(n)}$ 的估计量。选取 a 使MSE最小。

$$\begin{aligned} \text{MSE}(\bar{\theta}_a) &= D(\bar{\theta}_a) + [E(\bar{\theta}_a) - \theta]^2 \\ &= a^2 \frac{n}{(n+1)^2(n+2)} \theta^2 + \left(\frac{na}{n+1} - 1\right)^2 \theta^2, \end{aligned}$$

当 $a = \frac{n+2}{n+1}$ 时, $\bar{\theta}_a = a X_{(n)}$ 的MSE最小。

注: $E(X_{(n)}) = \frac{n}{(n+1)} \theta$
 $D(X_{(n)}) = \frac{n\theta^2}{(n+1)^2(n+2)}$

在均方误差意义下, 有些有偏估计优于无偏估计。

例: 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知。考虑 σ^2 的形如

$T = c \sum_{i=1}^n (X_i - \bar{X})^2$ 的估计量. 确定 c , 使对应的 **MSE** 最小.


注: $c = 1/(n-1)$ 时为无偏; $c = 1/n$ 为 **MLE**.

解: $\chi^2 := \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1) \Rightarrow T = c\sigma^2\chi^2,$

$$E(T) = c\sigma^2 E(\chi^2) = c\sigma^2(n-1),$$

$$D(T) = c^2\sigma^4 D(\chi^2) = c^2\sigma^4 2(n-1).$$

$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1);$



$$\begin{aligned} \text{MSE}(T) &= D(T) + [E(T) - \sigma^2]^2 \\ &= c^2\sigma^4 2(n-1) + [c\sigma^2(n-1) - \sigma^2]^2 \\ &= \sigma^4 [(n^2 - 1)c^2 - 2(n-1)c + 1]. \end{aligned}$$

当 $c = 1/(n+1)$ 时, **MSE** 最小。

四、均方误差（续）

定义：对参数估计问题，设有一个估计类，
称 $\bar{\theta}$ 是该估计类中的一致最小均方误差估计，
如果对该估计类中其它任意的 θ^* ，在参数
空间上都有

$$\text{MSE}(\bar{\theta}) \leq \text{MSE}(\theta^*).$$

注意：

一致最小均方误差估计通常在某个确定的估计类中进行。如果对估计类不加限制，一致最小均方误差估计一般不存在。

五、一致最小方差无偏估计

了解

在无偏估计类中，均方误差 = 方差。

按均方误差准则，在无偏估计类中，方差愈小愈先。

定义：对参数估计问题，设 $\bar{\theta}$ 是参数 θ 的一个无偏估计，如果对其它任意的 θ 的无偏估计 θ^* ，在参数空间上都有

$$D(\bar{\theta}) \leq D(\theta^*),$$

则称 $\bar{\theta}$ 是 θ 的一致最小方差无偏估计 (UMVUE)

Uniformly Minimum Variance Unbiased Estimate.

第三节、区间估计

□ 点估计:

对未知参数，适当构造统计量作为其估计（精度不知）。

□ 区间估计:

给出一个范围(区间)，希望它包含参数真值的可信度较高

Point estimate



Fishing with a spear

Confidence interval



Fishing with a net

例:

设总体 X 服从正态分布 $N(\mu, \sigma^2)$. σ^2 已知, μ 未知。

均值 μ 的MLE: $\bar{\mu} = \bar{X}$. ← 点估计, 精确度未知


$$\text{作 } G := \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1).$$

$$\Rightarrow P\left(-u_{0.975} \leq \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \leq u_{0.975}\right) = 0.95; (*)$$

其中, $u_{0.975}$ --- $N(0,1)$ 的下侧**0.975**分位数。

即: $P\{\bar{X} - 1.96\sigma / \sqrt{n} \leq \mu \leq \bar{X} + 1.96\sigma / \sqrt{n}\} = 0.95$.

区间 $(\bar{X} - 1.96\sigma / \sqrt{n}, \bar{X} + 1.96\sigma / \sqrt{n})$ 为随机区间,
区间端点均为统计量。该区间包含真值的可信度为**95%**。



一、置信区间

设 θ 是总体 X 的一个参数($\theta \in \Theta$), X_1, \dots, X_n 为样本,

对给定的 α ($0 < \alpha < 1$), 若有两个统计量


$\theta_L = \theta_L(X_1, \dots, X_n)$ 和 $\theta_U = \theta_U(X_1, \dots, X_n)$, 对 $\theta \in \Theta$, 满足

$$P_{\theta}(\theta_L \leq \theta \leq \theta_U) \geq 1 - \alpha,$$

则称随机区间 $[\theta_L, \theta_U]$ 为参数 θ 的置信水平为 $1 - \alpha$ 的置信区间;

θ_L 和 θ_U 分别称为(双侧)置信下限和置信上限;

$1 - \alpha$ 称为置信水平。



同等置信区间 要求 $P_{\theta}(\theta_L \leq \theta \leq \theta_U) = 1 - \alpha$.

同等置信区间是把给定的置信水平 $1 - \alpha$ 用足, 在总体为连续分布时常可实现。

注意：

不能说，参数 θ 落在区间 $[\theta_L, \theta_U]$ 的概率为 $1 - \alpha$.

θ 为定数，区间 $[\theta_L, \theta_U]$ 的两端点为随机变量。

↘ 随机区间

- When we have a 95% CI of (2, 4), we say: we are 95% confident that the interval (2, 4) contains the true population mean μ .
- But we cannot say: 95% probability that the true population mean μ is in (2, 4). (此处没有RV)

置信区间的频率解释

设 θ 是总体 X 的一个参数($\theta \in \Theta$),

重复抽样: x_1^k, \dots, x_n^k , $k = 1, \dots, M$.

每组样本观测值确定一个区间 $[\theta_L^k, \theta_U^k]$



这样的区间或者包含真值 θ , 或者不包含

注意到: $P(\theta_L \leq \theta \leq \theta_U) = (1 - \alpha)$,

由Bernoulli大数律, 含真值 θ 的区间约占 $100(1 - \alpha)\%$.


如: $\alpha = 0.01$, $M = 1000$:

含真值 θ 的区间约有 $M \cdot 99\% = 990$.



置信区间的频率解释

- 100人，每人从正态 $N(100, 18)$ 生成容量为36的样本。
- 每人从自己的样本中构造总体均值的95%的置信区间。
- 画图展示100个CI.



区间估计的优良性准则


- **可靠性**：区间包含未知参数的概率有多大？
- **精 度**：区间的长度。

若把可靠度提高, 则区间长度增加。

若把区间的长度减小, 可靠度也变小。

样本量一定时, **两者如何协调?**

一般, 给定置信水平,
以保证有一定的可靠度,
在此前提下, 尽量选择精度
更高的区间估计。



二、置信区间构造方法

枢轴量法：

Step 1. 构造样本和 θ 的函数 $G = G(X_1, \dots, X_n; \theta)$,
使 G 的分布已知且不含未知参数 θ (枢轴量);


Step 2. 对给定的置信水平 $1 - \alpha$, 选取常数 c, d , 使

$$P(c \leq G(X_1, \dots, X_n; \theta) \leq d) = 1 - \alpha;$$

Step 3. 从 $c \leq G \leq d$ 得到等价不等式：

$$\theta_L \leq \theta \leq \theta_U,$$

则 $P(\theta_L \leq \theta \leq \theta_U) = 1 - \alpha.$



则 $[\theta_L, \theta_U]$ 为 θ 的置信水平为 $1 - \alpha$ 的(同等)置信区间。

注记:

满足置信度要求的 c 与 d 通常不唯一。

若有可能，应选置信区间平均长度达到最短者。

当 G 的分布为**对称**分布时容易实现。


一般情况下，选使平均长度最短的 c 和 d 往往很难实现。

常选择 c 与 d ，使得两个尾部概率各为 $\alpha/2$ ，即

$$P(G < c) = P(G > d) = \alpha/2.$$

这样的置信区间称为**等尾置信区间**

在 G 的分布为偏态分布场合常采用



三、单个正态总体参数的置信区间

1. 均值的置信区间（方差已知的情形）

Step 1. 从均值 μ 的点估计出发：作 $G := \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$

Step 2. 对给定的置信水平 $1 - \alpha$ ，选取常数 c, d ，使

$$P(c \leq G \leq d) = 1 - \alpha; (*)$$

可取 $d = -c = u_{1-\alpha/2}$ --- $N(0,1)$ 的下侧 $1 - \alpha/2$ 分位数


Step 3. 从 $c \leq G \leq d$ 即 $c \leq \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \leq d$ 得等价不等式：

$$\bar{X} - u_{1-\alpha/2} \sigma / \sqrt{n} \leq \mu \leq \bar{X} + u_{1-\alpha/2} \sigma / \sqrt{n},$$

$$\text{则 } P(\bar{X} - u_{1-\alpha/2} \sigma / \sqrt{n} \leq \mu \leq \bar{X} + u_{1-\alpha/2} \sigma / \sqrt{n}) = 1 - \alpha.$$

$\Rightarrow \mu$ 的置信水平为 $1 - \alpha$ 的(同等)置信区间为

$$[\bar{X} - u_{1-\alpha/2} \sigma / \sqrt{n}, \bar{X} + u_{1-\alpha/2} \sigma / \sqrt{n}], \text{ 常表示为: } \bar{X} \pm u_{1-\alpha/2} \sigma / \sqrt{n}.$$



$u_{1-\alpha/2}$

对称取点

Point estimate \pm (Critical value)(Standard error)


standard error of \bar{X}

Four commonly used confidence level

$1 - \alpha$	α	$\alpha/2$	$u_{1-\alpha/2}$
.90	.10	.05	1.645
.95	.05	.025	1.96
.98	.02	.01	2.33
.99	.01	.005	2.575

Point estimate \pm (Critical value)(Standard error)

CI General Format




置信水平和样本容量的影响

Margin of error: the half-length of CI. It is the maximum likely difference between point estimate and the actual value of the parameter.

Conf Interval: $\bar{X} \pm u_{1-\sigma/2} \frac{\sigma}{\sqrt{n}}$,

Margin of Error $E = u_{1-\sigma/2} \frac{\sigma}{\sqrt{n}}$,

Sample size $n = \frac{(u_{1-\sigma/2})^2 \sigma^2}{E^2}$



置信水平减小时（分位点减），置信区间长度缩小。

样本量增大时，置信区间长度缩小（长度与样本量的平方根成反比）。

例:

例如:对给定的置信水平 $1 - \alpha = 0.95$ ($\alpha = 0.05$)

$$P\left(c \leq \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \leq d\right) = 0.95 \quad (*)$$

可取 $d = -c = u_{1-\alpha/2} = u_{0.975} = 1.96$



(对称取点时, 可使区间长度最短)

(*)等价于:

$$P(\bar{X} - 1.96\sigma / \sqrt{n} \leq \mu \leq \bar{X} + 1.96\sigma / \sqrt{n}) = 1 - \alpha.$$

则 μ 的置信水平为 0.95 的(同等)置信区间为

$$[\bar{X} - 1.96\sigma / \sqrt{n}, \bar{X} + 1.96\sigma / \sqrt{n}].$$



例：

用天平秤某物体的重量9次，得平均值为 15.4 (g).
已知天平秤量结果为正态分布，其标准差为0.1克。
试求该物体重量的 0.95 置信区间。

解： 此处 $1-\alpha=0.95$ ， $\alpha=0.05$ ，查表知 $u_{0.975}=1.96$ ，
于是该物体重量 μ 的0.95置信区间为

$$[\bar{x} - 1.96\sigma / \sqrt{n}, \bar{x} + 1.96\sigma / \sqrt{n}].$$

从而该物体重量的0.95置信区间为
[15.3347, 15.4653].

2. 均值的置信区间（方差未知的情形）


Step 1. 从均值 μ 的点估计出发：作 $G = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

用t分布代替正态分布

Step 2. 对给定的置信水平 $1-\alpha$ ，选取常数 c, d ，使

$$P\left(c \leq \frac{\bar{X} - \mu}{S / \sqrt{n}} \leq d\right) = 1 - \alpha; (*)$$

可取 $d = -c = t_{1-\alpha/2}(n-1)$ ，即 $t(n-1)$ 的下侧 $1-\alpha/2$ 分位数。



Step 3. (*)等价于

$$P(\bar{X} - t_{1-\alpha/2}(n-1)S / \sqrt{n} \leq \mu \leq \bar{X} + t_{1-\alpha/2}(n-1)S / \sqrt{n}) = 1 - \alpha.$$

\Rightarrow 则 μ 的置信水平为 $1-\alpha$ 的(同等)置信区间为

$$[\bar{X} - t_{1-\alpha/2}(n-1)S / \sqrt{n}, \bar{X} + t_{1-\alpha/2}(n-1)S / \sqrt{n}].$$

与方差已知的情形类似


Remark: The Effect of Sample Size

置信区间:

$$[\bar{X} - t_{1-\alpha/2}(n-1)S/\sqrt{n}, \bar{X} + t_{1-\alpha/2}(n-1)S/\sqrt{n}].$$

区间长度:

$$L = \frac{2 t_{1-\alpha/2}(n-1)S}{\sqrt{n}} \propto \frac{1}{\sqrt{n}}.$$



A *fourfold* increase in the sample size reduces the CI length by *half*.

3. 方差的置信区间（均值未知）


Step 1. 作 $G = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$. 注：当 μ 已知时作 $G = \sum \left(\frac{X_i - \mu}{\sigma} \right)^2$

Step 2. 对给定的置信水平 $1-\alpha$, 选取常数 c, d , 使

$$P\left(c \leq \frac{(n-1)S^2}{\sigma^2} \leq d\right) = 1-\alpha; (*)$$

可取 $d = \chi^2_{1-\alpha/2}(n-1)$, $c = \chi^2_{\alpha/2}(n-1)$,

分别为 $\chi^2(n-1)$ 分布的下侧 $1-\alpha/2$, $\alpha/2$ 分位数。



Step 3. (*) 等价于

$$P\left(\frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}\right) = 1-\alpha.$$

σ^2 的置信水平为 $1-\alpha$ 的(同等)置信区间为 $\left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)} \right]$.


四、单侧置信区间

均值的对称的CI：

$$[\bar{X} + u_{\alpha/2}\sigma / \sqrt{n}, \bar{X} + u_{1-\alpha/2}\sigma / \sqrt{n}].$$

亦可非对称的CI：

$$[\bar{X} - u_{\alpha_1}\sigma / \sqrt{n}, \bar{X} + u_{1-\alpha_2}\sigma / \sqrt{n}], \alpha_1 + \alpha_2 = 1.$$



常对均值的上界或下界感兴趣：单侧置信区间

四、单侧置信区间

实际问题中, 关心产品寿命的“下限”(标志质量, 越长越好)
杂质(毒性)含量的“上限”(越小越好)。


设 θ 是总体 X 的一个参数($\theta \in \Theta$), X_1, \dots, X_n 为样本,
对给定的 α ($0 < \alpha < 1$), 若有统计量 $\theta_L = \theta_L(X_1, \dots, X_n)$,
满足

$$P_{\theta}(\theta_L \leq \theta) \geq 1 - \alpha, \theta \in \Theta$$

则 θ_L 为参数 θ 的置信水平为 $1 - \alpha$ 的(单侧)置信下限。

若 $P_{\theta}(\theta_L \leq \theta) = 1 - \alpha, \theta \in \Theta$

则 θ_L 为参数 θ 的置信水平为 $1 - \alpha$ 的同等置信下限。



四、单侧置信区间


设 θ 是总体 X 的一个参数($\theta \in \Theta$), X_1, \dots, X_n 为样本,
对给定的 α ($0 < \alpha < 1$), 若有统计量 $\theta_U = \theta_U(X_1, \dots, X_n)$,
满足

$$P_{\theta}(\theta \leq \theta_U) \geq 1 - \alpha, \theta \in \Theta$$

则 θ_U 为参数 θ 的置信水平为 $1 - \alpha$ 的(单侧)置信上限。

若 $P_{\theta}(\theta \leq \theta_U) = 1 - \alpha, \theta \in \Theta$

则 θ_U 为参数 θ 的置信水平为 $1 - \alpha$ 的同等置信上限。



单侧置信限是(双侧)置信区间的特殊情形。

寻求(双侧)置信区间的方法可以用来寻找单侧置信限。

例： 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 均未知。

求：(1) μ 的置信水平为 $1-\alpha$ 的单侧置信下限；


(2) σ^2 的置信水平为 $1-\alpha$ 的单侧置信上限。

Step 1. 从均值 μ 的点估计出发：作 $G = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$

Step 2. 对给定的置信水平 $1-\alpha$ ，有

$$P\left(\frac{\bar{X} - \mu}{S / \sqrt{n}} \leq t_{1-\alpha}(n-1)\right) = 1-\alpha; (*)$$

$t_{1-\alpha}(n-1)$ 为 $t(n-1)$ 的下侧 $1-\alpha$ 分位数



Step 3. (*) 等价于

$$P(\mu \geq \bar{X} - \overset{\text{下限}}{t_{1-\alpha}(n-1)} S / \sqrt{n}) = 1-\alpha.$$

$\Rightarrow \mu$ 的置信水平为 $1-\alpha$ 的(同等)置信下限为 $\bar{X} - t_{1-\alpha}(n-1) S / \sqrt{n}$.

例： 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 均未知。

求：(1) μ 的置信水平为 $1-\alpha$ 的单侧置信下限；


(2) σ^2 的置信水平为 $1-\alpha$ 的单侧置信上限。

Step 1. 作 $G = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$.

Step 2. 对给定的置信水平 $1-\alpha$,

$$P\left(\frac{(n-1)S^2}{\sigma^2} \geq \chi_\alpha^2(n-1)\right) = 1-\alpha; (*)$$

$\chi_\alpha^2(n-1)$ 为 $\chi^2(n-1)$ 分布的下侧 α 分位数。



Step 3. (*) 等价于 **上限**

$$P\left(\sigma^2 \leq \frac{(n-1)S^2}{\chi_\alpha^2(n-1)}\right) = 1-\alpha.$$

则 σ^2 的置信水平为 $1-\alpha$ 的(同等)置信上限为 $\frac{(n-1)S^2}{\chi_\alpha^2(n-1)}$.

四、单侧置信区间

- 均值的下侧、上侧置信区间（置信水平 $1 - \alpha$ ，方差已知）

$$\text{下侧: } [\bar{X} - u_{\alpha} \frac{\sigma}{\sqrt{n}}, +\infty). \quad \text{上侧: } (-\infty, \bar{X} + u_{1-\alpha} \frac{\sigma}{\sqrt{n}}].$$

- 方差的下侧、上侧置信区间：

$$\text{下侧: } \left(\frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}, +\infty \right). \quad \text{上侧: } \left(0, \frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)} \right).$$

五、大样本置信区间

- Consider a **binomial experiment** with n trials and success probability p , number of successes is X :

$$X \sim B(n, p).$$

- The parameter is population proportion p .
- We compute **sample proportion x/n ---** the proportion of trials resulting in success.

五、大样本置信区间

Let p = binomial probability of success.

Let \bar{p} = **sample proportion** or proportion of success.

If $X \sim B(n, p)$, then

$$\bar{p} = \bar{X} = X/n$$

has **approximately normal distribution**

$$\bar{p} = \bar{X} \sim N(p, p(1-p)/n).$$

(np and $n(1-p)$ must each be at least 5)


考虑 0-1 分布的总体 X , $P(X=1)=p$, $P(X=0)=1-p$, p 未知,
样本 X_1, \dots, X_n .

Step 1. 作 $G = \frac{n\bar{X} - np}{\sqrt{np(1-p)}} \stackrel{\text{近似}}{\sim} N(0, 1)$ (中心极限定理)

Step 2. 对给定的置信水平 $1-\alpha$, 选取常数 $u_{1-\alpha/2}$, 使

$$P\left(\left|\frac{n\bar{X} - np}{\sqrt{np(1-p)}}\right| \leq u_{1-\alpha/2}\right) \approx 1-\alpha; (*)$$

$u_{1-\alpha/2}$ --- $N(0,1)$ 的下侧 $1-\alpha/2$ 分位数。



Step 3. (*) 式等价于 $P(ap^2 + bp + c \leq 0) \approx 1-\alpha$,

二次三项式, 开口向上

其中, $a = n + u_{1-\alpha/2}^2$, $b = -(2n\bar{X} + u_{1-\alpha/2}^2)$, $c = n\bar{X}^2$.

即 $P(p_L \leq p \leq p_U) \approx 1-\alpha$, $p_L = \frac{1}{2a}(-b - \sqrt{b^2 - 4ac})$, $p_U = \frac{1}{2a}(-b + \sqrt{b^2 - 4ac})$.

则 p 的置信水平为 $1-\alpha$ 的置信区间近似为 $[p_L, p_U]$

五、大样本置信区间

上述置信区间可近似化为：

$$\left[\bar{X} - u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}, \quad \bar{X} + u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}} \right].$$

对比正态总体情形，均值的置信区间：

$$\left[\bar{X} - u_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}}, \quad \bar{X} + u_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}} \right].$$

(相当于 σ^2 用 $\bar{X}(1-\bar{X})$ 代替)

Point estimate \pm (Critical value)(Standard error)

例：

调查某地100座桥梁，发现有 33 座有缺陷。求该地桥梁有缺陷比例的 90% 的置信区间。


解：置信区间

$$\left(\hat{p} - z^* \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + z^* \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right)$$

其中， $z^* = 1.645$ (0.95下侧分位数)，

$$\hat{p} = \frac{33}{100} = 0.33, \quad n = 100$$

置信区间 $(0.33 - 0.077, 0.33 + 0.077)$ ，
即 $(0.253, 0.407)$



例:

调查收视率 p , 为使 p 的 $1-\alpha$ 的置信区间长度不超过 d_0 , 应调查多少用户?

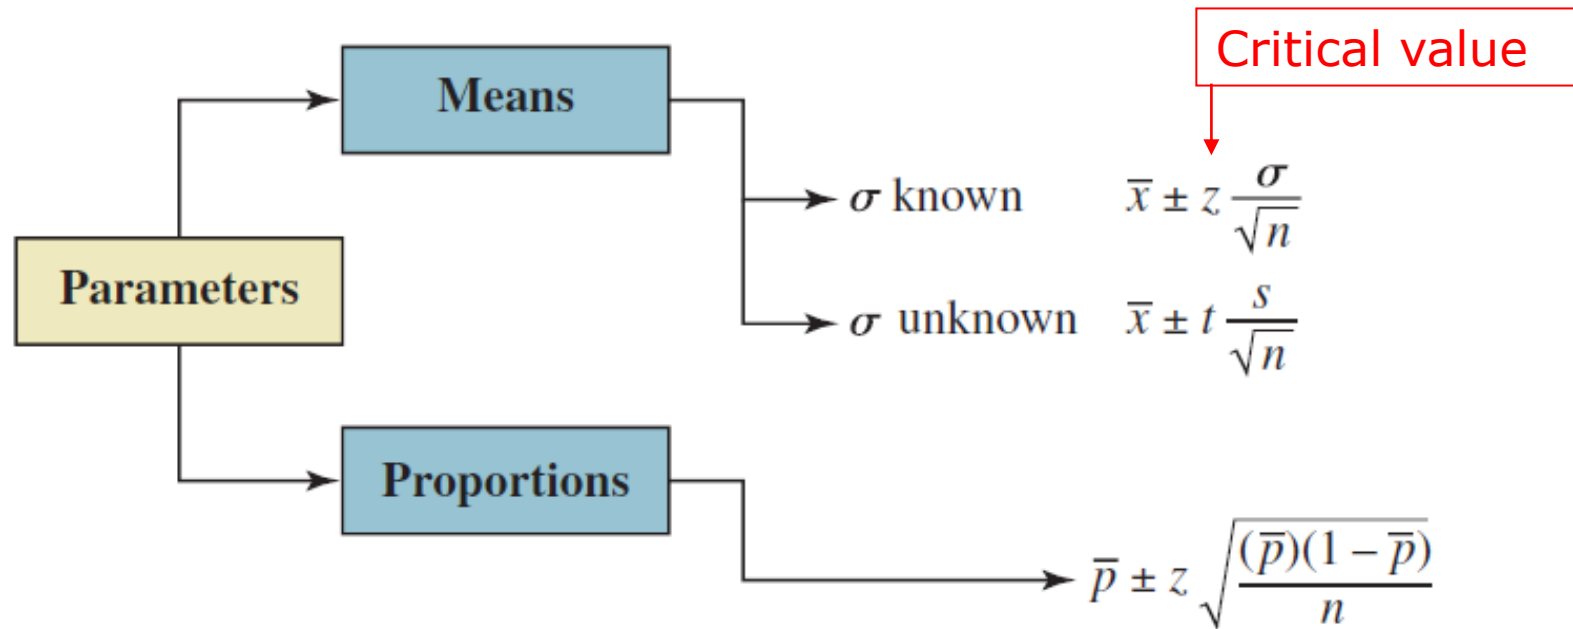
解: 置信区间的长度为: $d := 2u_{1-\alpha/2} \sqrt{\frac{\bar{X}(1-\bar{X})}{n}}$.

易知 $d \leq u_{1-\alpha/2} \sqrt{1/n}$ (因 $\bar{X}(1-\bar{X}) \leq 1/4$)

要使置信区间的长度不超过 d_0 , 只要

$$u_{1-\alpha/2} \sqrt{1/n} \leq d_0 \Rightarrow n \geq \left(\frac{u_{1-\alpha/2}}{d_0} \right)^2.$$

Comparison



General formula:

$$\sigma_{\bar{p}} \approx \sqrt{\frac{\bar{p}(1 - \bar{p})}{n}}$$

Point estimate \pm (Critical value)(Standard error)

CI for Poisson mean

For large n , we can use the z-interval $(\bar{X} + z_{\alpha/2} \cdot se(\bar{X}), \bar{X} + z_{1-\alpha/2} \cdot se(\bar{X}))$ as a $1-\alpha$ CI for λ .

Since Poisson variance is λ , we use $\hat{\lambda} = \bar{X}$ instead of sample variance

$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ to estimate the population variance. Hence $se(\bar{X}) = \sqrt{\frac{\bar{X}}{n}}$.

Therefore the two-sided $1-\alpha$ CI for λ is $(\bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}}{n}}, \bar{X} + z_{1-\alpha/2} \sqrt{\frac{\bar{X}}{n}})$.

The one-sided $1-\alpha$ CI for λ is $(\bar{X} + z_{\alpha} \sqrt{\frac{\bar{X}}{n}}, \infty)$ or $(-\infty, \bar{X} + z_{1-\alpha} \sqrt{\frac{\bar{X}}{n}})$.

Point estimate \pm (Critical value)(Standard error)

The End of Chapter 6